

IA & Applications

Rain Prediction

Challenge Prévision Météorologique Australie

Yasmina Bouziane


Sara Guendouz

Maxime Paviet

2025-2026 | 5 Mai 2026

01. INTRODUCTION

- **Problématique** : Anticiper les précipitations en Australie pour optimiser les activités humaines et économiques.
- **Données** : Exploitation du dataset "*Rain in Australia*" contenant des milliers de relevés.
- **Objectif** : Prédire s'il va pleuvoir le jour suivant via une classification supervisée.
- **Enjeux** : Gestion de l'humidité, pression atmosphérique et variabilité géographique.



01. INTRODUCTION

Phase	Le Thème	Modèle 1	Modèle 2
Duel 1	Les Fondations (Simplicité vs Spatial)	Régression Logistique (Baseline)	XGBoost (Gradient Boosting)
Duel 2	Arbres et Neurones (Lisibilité vs Profondeur)	Arbre de Décision (CART)	Deep Learning (Réseau Dense / MLP)
Duel 3	Ensemble Avancés	Random Forest (Bagging)	K-Nearest Neighbors (KNN)

02. PRÉPARATION & EDA



Exploration (EDA)

Analyse des distributions via histogrammes et boxplots pour détecter les **outliers**. Identification des corrélations fortes (Humidité/Pression).



Imputation

Gestion des manques par **SimpleImputer** : Médiane pour les numériques (résistance aux extrêmes) et Mode pour les catégorielles.



Scaling

Standardisation via **StandardScaler**. Crucial pour les modèles sensibles à l'échelle (MLP, KNN) pour garantir la convergence.

02. FEATURE ENGINEERING

Transformation & Création

- **Cible** : Conversion de RainTomorrow en binaire (0/1).
- **Nouveaux indicateurs** : Amplitude_Temperature, Pressure_Diff, Evolution_Humidity.
- **Encodage** : Traitement numérique des variables Location, WindGustDir, etc.
- **Partition** : Division Train/Test via train_test_split pour validation rigoureuse.

```
if 'Pressure3pm' in df_c.columns and 'Pressure9am' in df_c.columns:  
    df_c['Pressure_Diff'] = df_c['Pressure3pm'] - df_c['Pressure9am']  
  
if 'MaxTemp' in df_c.columns and 'MinTemp' in df_c.columns:  
    df_c['Amplitude_Temperature'] = df_c['MaxTemp'] - df_c['MinTemp']  
  
if 'Humidity3pm' in df_c.columns and 'Humidity9am' in df_c.columns:  
    df_c['Evolution_Humidity'] = df_c['Humidity3pm'] - df_c['Humidity9am']
```

03. Régression Logistique

Approche linéaire


- **Modèle sensible au déséquilibre des classes :**
Rééquilibrage des données via SMOTE
- **Optimisation :** Recherche des hyperparamètres
(GridSearch)

0.83

Accuracy

0.67


Rappel



03. Régression Logistique

Limites de la simplicité (interprétabilité)

- Le **Top 15 des variables influençant la pluie** illustre la limite de ce modèle
- L'**encodage One-Hot** écrase artificiellement le poids des variables continues pourtant cruciales comme l'humidité



04. XGBoost

Approche Spatiale


- **Gère nativement le déséquilibre** via le paramètre `scale_pos_weight`
- **Optimisation** : `RandomizedSearchCV`

0.82

Accuracy

0.79


Rappel



04. XGBoost

Interprétabilité pertinente

- Le **Top 15 des variables influençant la pluie** est parfaitement cohérent
- En découpant l'espace des données de manière non-linéaire, XGBoost ignore le "bruit" des colonnes binaires du vent.



05. ARBRE DE DÉCISION

Approche CART

- Transparence totale et capture des relations non-linéaires.
- **Optimisation** : RandomizedSearchCV + StratifiedKFold (5 plis).
- **Équilibrage** : `class_weight='balanced'` pour la classe minoritaire (Pluie).
- **Calibration** : CalibratedClassifierCV pour lisser les probabilités en escalier.

0.4023

Log Loss Brut


0.3541

Log Loss calibrée


0.87

ROC-AUC

05. ARBRE DE DÉCISION



05. ARBRE DE DÉCISION




918

Faux Positifs

3421

Faux Négatifs

05. ARBRE DE DÉCISION



06. DEEP LEARNING (MLP)

0.3136

Log Loss Brut

0.3144

Log Loss calibrée



0.901

ROC-AUC


Architecture & Keras Tuner

- Perceptron Multicouche optimisé via **Random Search**.
- **Régularisation** : Dropout et Batch Normalization pour stabiliser le gradient.
- **Early Stopping** : Patience de 5 époques sur *val_loss*.
- **Interprétabilité** : Permutation Importance pour briser l'aspect "boîte noire".

06. DEEP LEARNING (MLP)



06. DEEP LEARNING (MLP)




1271

Faux Positifs

2555

Faux Négatifs

06. DEEP LEARNING (MLP)



| Bilan du Duel : **Transparence vs Complexité**

Arbre de Décision



PERFORMANCE (AUC)

0.87

- ✓ **Transparence** : Logique humaine "en escalier".
- ✓ **Baseline** : Modèle de référence solide.
- ⚠ **Limite** : Rigidité face aux nuances météo.

Deep Learning (MLP)



PERFORMANCE (AUC)

0.901

- ✓ **Précision** : Capture les relations fluides.
- ↓ **Gain** : -25% de Faux Négatifs (3421 → 2555).
- 🔒 **Contrainte** : Effet "Boîte Noire" (Permutation).

07. RANDOM FOREST

1. Approche Algorithmique et Tuning

- Modèle d'ensemble pour réduire la variance.
- **Tuning** : 100 arbres, profondeur max 10, min_samples_leaf 4, min_samples_split 5
- **Gain Rappel** : Passage de 0.5820 à **0.6870**.

0.8594

SCORE ROC-AUC FINAL

RAPPORT BRUT


	precision	recall	f1-score	support
0.0	0.89	0.93	0.91	22098
1.0	0.72	0.58	0.64	6341
accuracy			0.86	28439
macro avg	0.80	0.76	0.78	28439
weighted avg	0.85	0.86	0.85	28439

RAPPORT OPTIMISÉ (Après Tuning)

	precision	recall	f1-score	support
0.0	0.90	0.85	0.88	22098
1.0	0.57	0.69	0.62	6341
accuracy			0.81	28439
macro avg	0.74	0.77	0.75	28439
weighted avg	0.83	0.81	0.82	28439

07. RANDOM FOREST

2. Évaluation des Performances




Matrice de Confusion RF

	Prédit Soleil	Prédit Pluie
Vrai Soleil	18 772	3 326
Vrai Pluie	1 990	4 351

07. RANDOM FOREST

3. Interprétabilité et Analyse des Erreurs



Analyse de l'Humidité à 15h selon le type d'erreur :

Resultat

Correct 49.346915



Faux Négatif (Raté) 50.839750

Faux Positif (Fausse Alerte) 67.287874

Name: Humidity3pm, dtype: float64

07. RANDOM FOREST

3. Interprétabilité et Analyse des Erreurs



08. K-NEAREST NEIGHBORS

1. Approche Algorithmique et Tuning

KNN : BRUT vs OPTIMISÉ

RAPPORT BRUT

	precision	recall	f1-score	support
0.0	0.91	0.74	0.82	22098
1.0	0.45	0.74	0.56	6341
accuracy			0.74	28439
macro avg	0.68	0.74	0.69	28439
weighted avg	0.81	0.74	0.76	28439

RAPPORT OPTIMISÉ (Après Tuning)

	precision	recall	f1-score	support
0.0	0.92	0.74	0.82	22098
1.0	0.46	0.77	0.57	6341
accuracy			0.75	28439
macro avg	0.69	0.75	0.70	28439
weighted avg	0.82	0.75	0.76	28439

Distance & Voisinage



- Algorithme spatial basé sur la distance euclidienne.
- **Tuning** : 9 voisins, pondération par l'inverse de la distance.
- **Sensibilité** : Excellent rappel de **0.77** (détecte mieux la pluie).
- **Compromis** : Précision faible (0.46) due à 5 807 fausses alertes.

0.8287

SCORE ROC-AUC FINAL

08. K-NEAREST NEIGHBORS


2. Évaluation des Performances



08. K-NEAREST NEIGHBORS

3. Interprétabilité et Analyse des Erreurs

Top 10 des variables climatiques les plus décisives (KNN)



Analyse de l'Humidité à 15h selon le type d'erreur (KNN) :

Resultat

Correct 49.319262



Faux Négatif (Raté) 50.276748

Faux Positif (Fausse Alerte) 60.043293

Name: Humidity3pm, dtype: float64

08. K-NEAREST NEIGHBORS

3. Interprétabilité et Analyse des Erreurs



Bilan du Duel : ANALYSE DES ERREURS

Erreurs de Type II (Faux Négatifs)

L'erreur la plus critique : rater un épisode pluvieux.

KNN (Le plus sûr)

1 442

Random Forest

1 990

Erreurs de Type I (Faux Positifs)

Le coût des fausses alertes (annulations inutiles).

Random Forest

3 326

KNN

5 807

09. Conclusion

Modèle	Accuracy	Recall (Pluie)	ROC-AUC
Régression Logistique	83%	0.67	0.865
XGBoost	82%	0.79	0.898
Arbre de Décision	85%	0.46	0.870
Random Forest	81%	0.69	0.859
Deep Learning (MLP)	87%	0.60	0.901
KNN	75%	0.77	0.829

MERCI DE VOTRE ATTENTION