



Rapport de Projet

IA et Applications - Rain Prediction Challenge

5 mai 2026

Yasmina Bouziane
Sara Guendouz
Maxime Paviet

SOMMAIRE

I. Introduction	2
II. Préparation des données	3
III. Duel 1 : Régression Logistique vs XGBoost	5
IV. Duel 2 : Arbre de décision vs DeepLearning (MLP)	10
V. Duel 3 : Random Forest vs KNN	18
VI. Conclusion	28

I. Introduction

1. Contexte

La météo a un impact direct sur beaucoup de nos activités. Avec le développement du Machine Learning, on peut désormais faire parler les données du passé pour anticiper l'avenir avec plus de précision.

Notre projet s'appuie sur cette idée. Nous avons utilisé des milliers de relevés météorologiques provenant d'Australie avec un objectif très concret : entraîner un modèle à deviner s'il va pleuvoir le jour suivant. Dans ce rapport, nous détaillons toute notre progression. Nous reviendrons d'abord sur la préparation des données, avant d'expliquer nos choix de modèles et d'analyser leurs résultats.

2. Election et Comparaison des Modèles

Pour ce projet, **six modèles** de Machine Learning ont été évalués. Afin d'optimiser l'analyse, ils ont été confrontés à travers trois duels thématiques, permettant d'identifier les approches les plus performantes avant la sélection finale.

Duel 1 : Baseline vs Performance Brute

La Régression Logistique mise sur la simplicité et la rapidité face à l'efficacité redoutable du XGBoost, conçu pour corriger ses erreurs de précision de manière séquentielle.

- **Régression Logistique** : Utilisée comme modèle de référence (*baseline*). Elle offre une rapidité d'exécution et une simplicité de mise en œuvre, bien que limitée par sa nature linéaire.
- **XGBoost** : Algorithme de *Gradient Boosting* reconnu pour son efficacité sur les données tabulaires. Il corrige séquentiellement ses erreurs pour maximiser la précision.

Duel 2 : Interprétabilité vs Complexité

L'Arbre de Décision privilégie une transparence totale des règles au risque du sur-apprentissage, tandis que le Deep Learning (MLP) mise sur la capture de schémas complexes au prix d'une opacité accrue.

- **Arbre de Décision** : Offre une transparence totale sur les règles de décision, mais présente un risque élevé de sur-apprentissage (*overfitting*).
- **Deep Learning (MLP)** : Performant pour capturer des schémas non linéaires complexes, il souffre néanmoins d'un effet « boîte noire » rendant l'explication des résultats plus difficile.

Duel 3 : Agrégation vs Proximité Spatiale

Le Random Forest s'appuie sur l'agrégation de multiples arbres pour gagner en stabilité, alors que le KNN fonde ses prédictions sur la ressemblance géométrique avec les données historiques.

- **Random Forest** : Utilise le *bagging* pour agréger les résultats de plusieurs centaines d'arbres indépendants, réduisant ainsi la variance globale du modèle.
- **KNN (K-Nearest Neighbors)** : Approche géométrique prédisant les précipitations en se basant sur la similarité (distance) avec les observations historiques les plus proches.

II. Préparation des données

La phase de préparation des données est l'étape la plus structurante du projet. Elle vise à transformer le jeu de données brut *weatherAUS.csv* du dataset "Rain in Australia" en un format numérique optimisé, exempt d'incohérences, pour maximiser la performance des modèles prédictifs.

Analyse exploratoire initiale (EDA)

Avant toute manipulation, une exploration a été menée pour comprendre la structure du dataset :

Identification des variables : Le jeu de données contient des variables météorologiques continues (température, humidité, pression, vitesse du vent) et catégorielles (localisation, direction du vent, présence de pluie le jour même).

Visualisation : Des histogrammes et des boîtes à moustaches (boxplots) ont été générés pour détecter la distribution des données et l'existence de valeurs aberrantes (*outliers*).

Analyse des corrélations : Une matrice de corrélation a permis d'identifier les variables ayant le plus d'impact sur la cible *RainTomorrow*, comme l'humidité à 15h ou la pression atmosphérique.

Gestion des valeurs manquantes (Imputation)

Le dataset présentait des lacunes importantes dans plusieurs colonnes. Pour éviter de supprimer trop d'informations, nous avons appliqué les stratégies d'imputation suivantes via *SimpleImputer* :

Variables numériques : Remplacement des valeurs manquantes par la **médiane**. La médiane a été préférée à la moyenne car elle est moins sensible aux valeurs extrêmes observées lors de l'EDA.

Variables catégorielles : Remplacement par la **valeur la plus fréquente (mode)** pour maintenir la cohérence des classes prédominantes dans chaque station météorologique.

Ingénierie des caractéristiques (Feature Engineering)

Cette étape, créditée de 3 points dans le barème, permet d'adapter les données aux algorithmes :

Transformation de la cible : La variable *RainTomorrow* a été convertie en format binaire (0 pour "No", 1 pour "Yes") pour permettre une classification supervisée.

Création et encodage des variables : De nouvelles caractéristiques (Amplitude_Temperature, Pressure_Diff, Evolution_Humidity) ont été créées pour capturer l'évolution météorologique au cours de la journée. Ensuite, les variables qualitatives telles que Location, WindGustDir, WindDir9am et WindDir3pm ont été encodées numériquement. Cela permet d'intégrer des informations temporelles, géographiques et directionnelles sans perte sémantique.

Traitement temporel : La colonne *Date* a été analysée pour extraire potentiellement des saisonnalités, bien que le focus principal soit resté sur les indicateurs de pression et d'humidité.

Normalisation et Standardisation

Les variables météorologiques utilisent des unités différentes (hPa pour la pression, % pour l'humidité, °C pour la température). Pour éviter que les variables à forte magnitude (pression autour de 1000 hPa) n'écrasent les autres, nous avons utilisé le *StandardScaler* :

Chaque caractéristique numérique a été centrée autour de 0 avec un écart-type de 1. Cette étape est cruciale pour les modèles sensibles à l'échelle, garantissant une convergence plus rapide des algorithmes d'apprentissage.

Partitionnement des données

Pour garantir une évaluation rigoureuse, les données ont été divisées en deux ensembles distincts via *train_test_split* :

Ensemble d'entraînement (Train set) : Utilisé pour l'apprentissage des modèles et le réglage des paramètres.

Ensemble de test (Test set) : Conservé intact jusqu'à la phase finale pour mesurer la capacité de généralisation du modèle sur des données jamais vues, conformément aux exigences de validation du projet.


III. Duel 1 - Régression Logistique vs XGBoost :

Pour ce premier "duel", nous opposons deux philosophies de modélisation diamétralement différentes. D'un côté, la **Régression Logistique**, qui incarne la simplicité des modèles linéaires : elle cherche à tracer une frontière droite pour séparer les classes. De l'autre côté, **XGBoost**, un modèle d'ensemble itératif plus lourd, qui adopte une approche "spatiale" en découpant l'espace des variables en de multiples régions non-linéaires grâce à des arbres de décision.

3.1 Le Challenger : La Régression Logistique (L'approche par la simplicité)

La **Régression Logistique** sert de modèle de référence (baseline) à notre étude. Son objectif est d'établir une équation pondérée simple pour évaluer la probabilité de pluie.


- **Préparation et Entraînement** : Ce modèle étant sensible au déséquilibre des classes, nous avons dû générer des données synthétiques via la méthode SMOTE pour rééquilibrer les jours secs et pluvieux lors de l'entraînement. Une recherche d'hyperparamètres (GridSearch) a permis d'optimiser sa régularisation.
- **Performances** : Le modèle offre une base solide avec une exactitude globale (Accuracy) de 83%. Son Rappel sur la classe minoritaire "Pluie" est de 0.67 (il détecte 67% des jours pluvieux), pour une précision de 0.61. Sa courbe ROC démontre une bonne capacité de séparation globale avec une **AUC de 0.865**.



Rapport de classification complet :

	precision	recall	f1-score	support
Beau temps	0.89	0.94	0.92	22064
Pluie	0.75	0.60	0.67	6375
accuracy			0.87	28439
macro avg	0.82	0.77	0.79	28439
weighted avg	0.86	0.87	0.86	28439


- La limite de la simplicité (Interprétabilité) :** Si la Régression Logistique a l'avantage d'être transparente, notre graphique du Top 15 des variables met en lumière sa principale faiblesse face à nos données. Le classement est totalement dominé par les variables de direction du vent (*WindDir9am_NNE*, *WindDir3pm_NNW*, etc.). L'algorithme a été "piégé" par l'encodage One-Hot (qui a transformé le vent en de multiples colonnes binaires), écrasant artificiellement le poids des variables continues pourtant cruciales comme l'humidité.



3.2 Le Poids Lourd : XGBoost (L'approche spatiale et itérative)

Face aux limites du modèle linéaire, XGBoost propose de construire une succession d'arbres de décision. Chaque nouvel arbre se concentre spécifiquement sur la zone de "l'espace des caractéristiques" où les arbres précédents se sont trompés.


- **Préparation et Entraînement** : Contrairement à la Régression Logistique, XGBoost ne nécessite pas de SMOTE. Il gère le déséquilibre nativement via le paramètre `scale_pos_weight`, qui applique une lourde pénalité mathématique lorsqu'une pluie réelle est manquée. Nous l'avons optimisé via un `RandomizedSearchCV`.
- **Performances** : XGBoost surclasse nettement le modèle linéaire sur l'objectif métier. Son **Rappel bondit à 0.79** (contre 0.67), ce qui signifie qu'il anticipe près de 8 épisodes pluvieux sur 10. Bien qu'il concède une légère baisse de précision (0.58), son accuracy reste stable à 82% et son **AUC atteint 0.898**, prouvant une nette supériorité prédictive.



--- RAPPORT DE CLASSIFICATION XGBOOST ---

	precision	recall	f1-score	support
0	0.93	0.83	0.88	22064
1	0.58	0.79	0.67	6375
accuracy			0.82	28439
macro avg	0.76	0.81	0.77	28439
weighted avg	0.85	0.82	0.83	28439

- **La pertinence métier (Interprétabilité)** : En découpant l'espace des données de manière non-linéaire, XGBoost ignore le "bruit" des colonnes binaires du vent. Son Top 15 des variables est parfaitement cohérent avec la réalité météorologique : l'humidité à 15h (**Humidity3pm**) s'impose comme le prédicteur absolu, suivie du fait qu'il ait plu le jour même (**RainToday_Yes**) et du niveau d'ensoleillement (**Sunshine**).



3.3 Bilan du Duel : Linéarité vs Non-Linéarité

Ce duel illustre parfaitement le compromis classique en Machine Learning.

La **Régression Logistique** a rempli son rôle : elle est rapide, robuste, et offre une excellente *baseline* (AUC de 0.865). Cependant, son incapacité à gérer correctement un grand volume de variables catégorielles encodées la rend aveugle aux véritables causes météorologiques dans notre jeu de données.

XGBoost remporte cette confrontation haut la main. En s'affranchissant des contraintes linéaires, il comprend beaucoup mieux la structure sous-jacente du climat australien. Sur le plan opérationnel, son Rappel de 0.79 en fait un outil de prévention beaucoup plus fiable pour alerter la population ou les agriculteurs de l'arrivée de la pluie, justifiant ainsi son statut de modèle "Poids Lourd".

IV. Duel 2 - Arbre de décision vs DeepLearning (MLP)

Pour ce second "duel", nous opposons deux philosophies diamétralement différentes : la transparence face à la complexité. D'un côté, l'**Arbre de Décision**, qui incarne une logique humaine et limpide : il segmente le problème étape par étape via des règles strictes et parfaitement interprétables en "escalier". De l'autre, le **réseau de neurones (MLP)**, véritable "boîte noire" mathématique : grâce à ses couches interconnectées, il tord l'espace des variables pour capturer des relations fluides et infiniment complexes, sacrifiant la lisibilité au profit d'une puissance prédictive brute.

4.1.1. Arbre de décision

Le second modèle développé est un Arbre de Décision (CART). L'avantage inhérent de ce modèle réside dans sa grande transparence et sa capacité à capturer des relations non-linéaires sans nécessiter de normalisation lourde des données.

Pour limiter le risque fort de sur-apprentissage propre aux arbres, nous avons mis en place une validation croisée stratifiée robuste (StratifiedKFold à 5 plis), couplée à une recherche d'hyperparamètres via RandomizedSearchCV. L'argument `class_weight='balanced'` a été spécifié pour pénaliser davantage les erreurs sur la classe minoritaire (jours de pluie).


Configuration Optimale retenue : La profondeur maximale de l'arbre a été régularisée à 10, avec un minimum d'échantillons par feuille de 20 et le critère de séparation gini.

4.1.2. Fiabilité et Calibration des Probabilités

Par nature, un arbre de décision renvoie des probabilités en escalier (basées sur le ratio des classes dans chaque feuille terminale). Pour lisser et corriger ces estimations, le modèle a été encapsulé dans un CalibratedClassifierCV (méthode isotonique).

Résultats Comparatifs : L'arbre calibré obtient un score ROC-AUC de 0.87 et un PR-AUC de 0.711. La pertinence de la calibration est démontrée par les métriques probabilistes :


- **Log-Loss** : Amélioration de 0.4023 vers 0.3541.



4.1.3. Diagnostic des Prédictions

La matrice de confusion met en lumière le comportement décisionnel de l'arbre par rapport au réseau de neurones.


Bilan des Erreurs : L'arbre a généré 918 Faux Positifs et 3421 Faux Négatifs. L'exactitude globale (Accuracy) s'établit à 84,74 %. Le rappel sur la classe "Pluie" est de 46,34 %, indiquant la capacité du modèle à ne rater qu'une faible portion des jours pluvieux réels.




4.1.4. Interprétabilité (Feature Importance & PDP)

Contrairement au réseau de neurones, l'arbre de décision offre une mesure native de l'importance des variables, calculée via la réduction d'impureté (Gini/Entropy) apportée par chaque nœud.

La variable la plus discriminante pour les scissions de l'arbre est Humidity3pm, suivie de WindGustSpeed. Le diagramme de dépendance partielle (PDP) confirme l'importance de ce facteur directeur.



Observation du PDP : Le graphique illustre parfaitement le fonctionnement de l'arbre de décision avec sa structure typique en marches d'escalier. On y observe des sauts de probabilité brutaux à chaque scission importante, notamment une première marche nette lorsque la valeur standardisée de l'humidité franchit 0.0, et un bond critique très marqué faisant exploser la probabilité de pluie au-delà du seuil de 1.5.



Rapport de classification détaillé :

	precision	recall	f1-score	support
Beau temps	0.86	0.96	0.91	22064
Pluie	0.76	0.46	0.58	6375
accuracy			0.85	28439
macro avg	0.81	0.71	0.74	28439
weighted avg	0.84	0.85	0.83	28439

4.2.1. Deep Learning (MLP)

Pour ce modèle, nous avons implémenté un Perceptron Multicouche (MLP) à l'aide de la librairie TensorFlow/Keras. Afin de garantir une architecture optimale et d'éviter un choix arbitraire des hyperparamètres, nous avons utilisé l'algorithme de recherche aléatoire intégré à **KerasTuner**.

La recherche a porté sur le nombre de neurones par couche dense, le taux d'apprentissage de l'optimiseur Adam, et les taux de *Dropout* (régularisation pour prévenir le sur-apprentissage). L'entraînement intègre également des couches de *Batch Normalization* pour stabiliser le gradient, ainsi qu'une procédure d'*Early Stopping* monitorée sur la perte de validation (val_loss) avec une patience de 5 époques.

Résultats du Tuning : L'architecture retenue par KerasTuner comprend une première couche de 64 neurones avec un Dropout de 0.2, une seconde couche de 64 neurones, et un learning rate optimisé à 0.001.


4.2.2. Évaluation des Performances et Calibration Probabiliste

Face au déséquilibre naturel des classes (les jours de pluie étant minoritaires), la simple exactitude (*accuracy*) n'est pas une métrique pertinente. Nous avons privilégié l'aire sous la courbe ROC (ROC-AUC) et l'aire sous la courbe Precision-Recall (PR-AUC).

De plus, les réseaux de neurones ayant tendance à produire des probabilités mal calibrées (souvent trop confiantes), nous avons appliqué une post-calibration par **Régression Isotonique** sur les prédictions brutes. L'impact de cette calibration a été mesuré via le Brier Score et le Log-Loss.

Résultats des métriques :

- **ROC-AUC** : 0.901 | **PR-AUC** : 0.766
- **Log-Loss** : Réduction de 0.3136 à 0.3144.




4.2.3. Analyse des Erreurs

L'analyse de la matrice de confusion permet de traduire les performances statistiques en impacts métier concrets (seuil de décision fixé à 0.5).


Bilan de la Matrice :

- **Vrais Positifs / Vrais Négatifs** : Le modèle identifie correctement 3820 jours de pluie et 20793 jours de beau temps.
- **Faux Positifs (Erreur de Type I)** : 1271 fausses alertes. L'impact se traduit par des annulations préventives inutiles (transports, agriculture).
- **Faux Négatifs (Erreur de Type II)** : 2555 pluies non anticipées, exposant la population à des intempéries non prévues.




4.2.4. Interpr  tabilit   Globale et Locale

Afin de briser l'aspect "bo  te noire" du MLP, nous avons calcul   l'importance des variables par permutation (Permutation Importance), mesurant la chute de l'AUC lorsqu'une variable est al  atoirement brouill  e. La variable la plus influente s'est av  r  e   tre Humidity3pm.



Pour comprendre l'effet marginal de cette variable sur la pr  diction, nous avons g  n  r   un Partial Dependence Plot (PDP). **Observation du PDP** : Le graphe montre une augmentation continue et non-lin  aire de la probabilit   moyenne de pluie, qui s'acc  l  re de plus en plus    mesure que l'humidit   augmente.



Rapport de classification complet :

	precision	recall	f1-score	support
Beau temps	0.89	0.94	0.92	22064
Pluie	0.75	0.60	0.67	6375
accuracy			0.87	28439
macro avg	0.82	0.77	0.79	28439
weighted avg	0.86	0.87	0.86	28439

4.3 Bilan du Duel : Transparence vs Complexité

Ce duel illustre parfaitement le compromis ultime en Machine Learning : l'interprétabilité face à la puissance brute.

L'**Arbre de Décision** a parfaitement rempli son rôle de modèle de référence : il est limpide, rassurant à expliquer, et offre une très solide *baseline* (**AUC de 0.87**). Cependant, sa logique décisionnelle rigide "en escalier" finit par le brider face aux variations infiniment nuancées des véritables phénomènes météorologiques.

Le **Deep Learning (MLP)** remporte cette confrontation sur le plan de l'efficacité prédictive. En déployant ses couches de neurones, il saisit la nature fluide et continue du climat australien avec une précision redoutable (**AUC de 0.901**). Sur le plan opérationnel, sa capacité supérieure à détecter les véritables jours de pluie (**faisant chuter drastiquement les faux négatifs de 3421 à 2555**) en fait l'outil d'anticipation le plus sécurisant pour des secteurs à risque comme l'agriculture, justifiant pleinement les efforts techniques déployés pour percer les secrets de sa "boîte noire".

V. Duel 3 : Random Forest vs KNN

Pour ce duel, nous opposons deux visions radicalement différentes de l'apprentissage automatique. D'un côté, le **Random Forest**, qui incarne la puissance des modèles d'ensemble : il s'appuie sur une "sagesse collective" en combinant des centaines d'arbres de décision pour stabiliser ses prédictions et réduire la variance. De l'autre côté, le **KNN** (K-Nearest Neighbors), un modèle géométrique dit "paresseux", qui ne crée aucune règle explicite mais se contente de comparer la proximité mathématique entre les points : il juge un jour futur à l'aune de ses voisins les plus ressemblants dans le passé.

5.1 Random Forest

1. Approche Algorithmique et Tuning

Pour améliorer les performances de prédiction et réduire la variance inhérente aux arbres de décision simples, nous avons implémenté un modèle d'ensemble : le **Random Forest**. Ce modèle repose sur l'agrégation de multiples arbres de décision entraînés sur des sous-échantillons des données. Afin de gérer le fort déséquilibre des classes de notre variable cible, nous avons intégré la méthode de sur-échantillonnage SMOTE (Synthetic Minority Over-sampling Technique) au sein d'un pipeline. Pour optimiser les hyperparamètres du modèle, une recherche aléatoire **RandomizedSearchCV** a été exécutée avec une validation croisée à 3 plis, en ciblant la métrique du Rappel.

- Les paramètres explorés comprenaient le nombre d'arbres, la profondeur maximale, ainsi que les critères de division `min_samples_split` et `min_samples_leaf`.
- **Configuration optimale retenue** : La recherche a identifié la meilleure combinaison suivante : 100 arbres, une profondeur maximale limitée à 10, un minimum de 5 échantillons pour séparer un nœud interne , et un minimum de 4 échantillons par feuille.
- Cette optimisation a permis de faire passer le score de Rappel moyen en validation croisée de 0.5820 (modèle brut) à 0.6870 (modèle tuné).


2 Évaluation des Performances

Le modèle Random Forest optimisé offre d'excellentes capacités de généralisation.

Rapport de classification : Après tuning, le modèle atteint un rappel de 0.69 pour la classe "Pluie", contre seulement 0.58 pour la version brute. Cela signifie que 69% des jours de pluie réels sont correctement anticipés.

L'exactitude globale Accuracy s'établit à 0.81 et le f1-score de la classe minoritaire est de 0.62. La précision de 0.57 indique que parmi toutes les prédictions de pluie, plus de la moitié sont avérées.


Performance globale : Le modèle Random Forest se distingue avec un score ROC-AUC final très performant de 0.8594, démontrant une forte capacité à distinguer les jours pluvieux des jours secs.



- **Analyse de la Matrice de Confusion**

Pour traduire les scores statistiques en impacts réels, nous avons examiné la matrice de confusion du modèle optimisé (seuil par défaut à 0.5).


- **Vrais Positifs / Vrais Négatifs** : Le modèle Random Forest a correctement identifié 4 351 jours de pluie (Vrais Positifs) et 18 772 jours secs (Vrais Négatifs).
- **Faux Négatifs (Erreur de Type II - Ratés)** : Il a manqué 1 990 jours de pluie (prédits comme "Soleil"). C'est l'erreur la plus critique dans un système d'alerte, car elle laisse les utilisateurs sans prévention face aux intempéries.
- **Faux Positifs (Erreur de Type I - Fausses Alertes)** : Il a déclenché 3 326 fausses alertes (jours secs prédits comme "Pluie"). Bien que moins dangereuse qu'un jour de pluie raté, une accumulation de fausses alertes peut réduire la confiance des utilisateurs dans le système.




3 Interprétabilité et Analyse des Erreurs

Afin de comprendre le comportement décisionnel du modèle, nous avons mené une analyse de l'importance des variables et une étude détaillée de ses erreurs.


- **Feature Importance** : La structure en forêt permet d'extraire l'importance globale de chaque variable. L'humidité mesurée à 15h s'est imposée comme le prédicteur le plus décisif.



- Analyse des erreurs** : Nous avons classé les prédictions du modèle en fonction des Labels : "Correct", "Faux Négatif" et "Faux Positif". L'analyse de l'humidité moyenne à 15h pour chaque catégorie révèle que le modèle a tendance à générer des Faux Positifs (Fausse Alerte) lorsque l'humidité est anormalement élevée (moyenne à 67.28%), tandis que les Faux Négatifs (Raté) se produisent lorsque l'humidité est proche de la moyenne des jours sans pluie (autour de 50.8%).
- Distribution des erreurs** : Le graphique en boîte à moustaches ("Distribution de l'Humidité selon les erreurs") confirme visuellement cette tendance : la médiane de l'humidité à 15h pour les "Fausses Alertes" est nettement supérieure à celle des prédictions correctes, soulignant la sensibilité du modèle à cette variable.



- **Partial Dependence Plot (PDP)** : Enfin, un diagramme de dépendance partielle généré sur un échantillon réduit pour l'humidité à 15h illustre clairement le seuil critique à partir duquel la probabilité de pluie décolle selon le Random Forest, soit 50%.



5.2 K-Nearest Neighbors

1. Approche Algorithmique et Tuning


Nous avons enfin testé un algorithme fondé sur la distance spatiale entre les observations : les K-Plus Proches Voisins (KNN). Tout comme pour le Random Forest, la technique SMOTE a été utilisée en amont pour équilibrer les classes d'apprentissage. Une étape de tuning par RandomizedSearchCV a été menée pour identifier les meilleurs paramètres spatiaux du modèle :

- Les tests ont porté sur le nombre de voisins (`n_neighbors` testé avec 5 et 9), les poids accordés aux voisins (`weights` uniform ou distance), avec la distance Euclidienne (`p=2`).
- **Configuration optimale retenue** : Le meilleur modèle a été obtenu en considérant les 9 plus proches voisins et en pondérant leur vote par l'inverse de leur distance (`weights: 'distance'`).
- Le tuning a permis d'améliorer le Rappel en validation croisée, passant d'une moyenne de 0.7463 à 0.7688.

2. Évaluation des Performances

Le modèle KNN présente un profil de prédiction très orienté vers la détection de la classe minoritaire, au détriment de la précision.


- **Rapport de classification** : Le KNN optimisé affiche un excellent Rappel de 0.77 sur la classe "Pluie" (contre 0.74 en brut). Il détecte donc 77% des épisodes pluvieux.
- **Le compromis Précision/Rappel** : Cette grande sensibilité génère toutefois de nombreux Faux Positifs, ce qui fait chuter la précision à 0.46. L'exactitude globale (Accuracy) se situe à 0.75.
- **Performance globale** : Le score ROC-AUC final du KNN s'établit à 0.8287, ce qui en fait un modèle robuste mais légèrement inférieur aux performances du Random Forest (0.8594).



● Analyse de la Matrice de Confusion

L'observation de la matrice de confusion du KNN confirme le compromis Précision/Rappel identifié précédemment.


- **Vrais Positifs / Vrais Négatifs** : Le KNN a détecté 4 899 jours de pluie (Vrais Positifs) et 16 291 jours secs (Vrais Négatifs).
- **Faux Négatifs (Erreur de Type II - Ratés)** : Le modèle s'est trompé sur 1 442 jours de pluie. Son point fort est donc une excellente couverture : il rate nettement moins d'épisodes pluvieux que le Random Forest (qui en ratait 1 990).
- **Faux Positifs (Erreur de Type I - Fausses Alertes)** : Ce gain en sensibilité a un coût direct : le KNN génère 5 807 fausses alertes, un chiffre très élevé. Le modèle a une forte tendance à "sur-prédire" la pluie, ce qui peut engendrer des coûts inutiles dans certains cas d'usage.



3. Interprétabilité et Analyse des Erreurs

L'algorithme KNN ne possédant pas de mécanisme natif pour évaluer l'importance des variables, des méthodes agnostiques ont dû être employées.

- **Permutation Importance** : Cette méthode nous a permis de quantifier l'impact de chaque variable en mesurant la baisse de performance lorsque ses valeurs sont mélangées. L'humidité à 15h s'est révélée, ici aussi, déterminante.




- **Analyse de l'erreur** : L'étude des moyennes d'humidité à 15h selon le type de prédiction (Correct, Faux Négatif, Faux Positif) met en évidence les limites spatiales du KNN :
 - **Correct** : 49.32 %
 - **Faux Négatif (Raté)** : 50.28 %
 - **Faux Positif (Fausse Alerte)** : 60.04 %


Bien que la tendance soit la même que pour le Random Forest (les fausses alertes sont liées à une humidité plus forte), on remarque que l'écart est moins prononcé (60.04 % pour le KNN contre 67.29 % pour le Random Forest).

- **Distribution des erreurs** : Le graphique en boîte à moustaches (*Distribution de l'Humidité selon les erreurs - KNN*) illustre parfaitement cette dynamique.

On observe un fort chevauchement des distributions entre les différentes catégories. La médiane des Faux Négatifs est presque identique à celle des prédictions correctes. Cela démontre la difficulté de l'algorithme à séparer clairement les classes frontalières en se basant uniquement sur la distance euclidienne.



- **Partial Dependence Plot (PDP)** : Un PDP a été tracé sur un échantillon réduit des données pour le KNN, mettant en évidence une sensibilité locale plus "bruitée" (en escalier) face à la hausse de l'humidité à 15h, typique du fonctionnement par voisinage.



5. 3 Bilan : Sagesse Collective vs Proximité Géométrique

L'analyse des erreurs confirme la supériorité opérationnelle du **Random Forest**, qui s'impose par son équilibre :

- **Faux Négatifs (Manqués)** : Le KNN est le plus "prudent" avec seulement 1 442 erreurs de type II, mais le Random Forest reste performant en limitant les ratés à 1 990 jours.
- **Faux Positifs (Fausses Alertes)** : C'est ici que le **Random Forest** triomphe, avec seulement 3 326 fausses alertes contre 5 807 pour le KNN.

En résumé, si le KNN ne rate rien, il "panique" trop souvent. Le **Random Forest** offre une prévision beaucoup plus sereine en réduisant drastiquement les annulations inutiles, tout en gardant un excellent niveau de détection.

VI. Conclusion

Le projet "Rain Prediction Challenge" nous a confronté à une problématique classique et majeure de l'Intelligence Artificielle : prédire un événement météorologique critique (la pluie) à partir d'un large volume de données hétérogènes. Ce défi a mis en exergue l'importance capitale de la préparation des données. Les étapes d'imputation, d'ingénierie des caractéristiques (création de variables d'évolution temporelle) et de standardisation ont constitué un socle indispensable pour permettre à nos algorithmes de converger efficacement. Par ailleurs, le fort déséquilibre des classes nous a obligés à dépasser la simple "Exactitude" (Accuracy) pour évaluer nos modèles à travers des métriques beaucoup plus pertinentes pour la gestion des risques, telles que le Rappel (Recall) et l'aire sous la courbe (ROC-AUC).

Synthèse des Modèles :

L'approche par confrontation (duels idéologiques) nous a permis de tirer des conclusions riches sur le comportement des différentes familles d'algorithmes face à un problème climatique :

- **Linéarité vs Non-Linéarité** : Le premier duel a opposé la simplicité de la Régression Logistique à l'approche spatiale de XGBoost. Si le modèle linéaire offre une base solide, il s'est fait piéger par le volume des variables catégorielles encodées (direction du vent), là où les algorithmes basés sur des arbres ont su isoler la véritable cause météorologique : l'humidité.
- **Sensibilité vs Précision (Le cas du KNN)** : Le K-Nearest Neighbors s'est distingué par sa très grande sensibilité (Rappel de 0.77), ratant très peu d'épisodes pluvieux. Cependant, ce modèle spatial génère un bruit excessif (plus de 5800 fausses alertes), rendant son déploiement coûteux d'un point de vue opérationnel.
- **Interprétabilité vs Boîte Noire** : L'Arbre de Décision et le Random Forest ont brillé par leur transparence, confirmant sans équivoque que l'humidité à 15h (**Humidity3pm**) est le prédicteur absolu de la pluie du lendemain. À l'inverse, le réseau de neurones (MLP), bien que mathématiquement puissant, a nécessité des techniques complexes (Permutation Importance) pour justifier ses prédictions.

Le Modèle Gagnant :

À l'issue de notre étude, **XGBoost** s'impose comme le modèle le plus abouti et opérationnel de notre panel. Bien que le Deep Learning (MLP) ait obtenu la meilleure capacité de séparation théorique avec une AUC de 0.901, XGBoost le talonne de très près (AUC de 0.898) tout en offrant une bien meilleure utilité métier. Avec un Rappel de 0.79, XGBoost est capable d'anticiper près de 8 jours de pluie sur 10, surpassant largement la Régression Logistique (0.67) et le Random Forest (0.69). Il gère nativement le déséquilibre des classes et conserve une interprétabilité native claire, ce qui en fait l'outil d'alerte météorologique idéal.